

RAPPORT D'ANALYSE STATISTIQUE

Stratégie de Lutte Antivectorielle contre le Paludisme :

Déterminants Environnementaux de la Densité Parasitaire
et Priorisation Géographique des Interventions

*Modélisation par Régression Linéaire (OLS)
et Sélection de Variables par Critère AIC*

Rédigé par : Fossi Edmond

Date : Juillet 2026

Table des matières

1	Contexte et Question de Recherche	2
2	Volet 1 — Cadre Théorique	2
2.1	Pourquoi la distribution brute de la densité parasitaire peut-elle poser problème dans un modèle OLS?	2
2.2	Que suggère le théorème de Gauss-Markov?	3
3	Volet 2 — Modélisation Statistique	3
3.1	Préparation des données	3
3.2	Modèle de régression linéaire complet (6 variables)	4
3.3	Vérification des hypothèses de Gauss-Markov	4
3.4	Sélection des variables significatives par le critère AIC	5
3.5	Interprétation de l'effet de l'altitude	5
4	Volet 3 — Note Stratégique : Priorisation Géographique des Interventions	6
4.1	Constat statistique	6
4.2	Recommandations opérationnelles	6
4.3	Limites et prudence méthodologique	7
5	Conclusion Générale	7

1. Contexte et Question de Recherche

Le paludisme demeure l'une des principales causes de morbidité et de mortalité dans les zones tropicales, en particulier en Afrique subsaharienne. Sa transmission dépend étroitement d'un ensemble de facteurs environnementaux — altitude, température, humidité, précipitations, proximité des points d'eau stagnante et nature du sol — qui déterminent la présence et la survie du vecteur anophèle ainsi que la dynamique du parasite *Plasmodium* chez l'hôte humain.

Les autorités sanitaires suspectent que l'altitude, en interaction avec les conditions climatiques locales, définit des zones de transmission distinctes, certaines étant nettement plus à risque que d'autres. Identifier ces déterminants revêt un intérêt opérationnel majeur : il permet d'optimiser l'allocation de ressources de lutte antivectorielle qui restent structurellement limitées (moustiquaires imprégnées d'insecticide de longue durée, campagnes de pulvérisation intra-domiciliaire, assainissement des gîtes larvaires) en ciblant en priorité les zones de vulnérabilité maximale plutôt que de disperser l'effort de manière uniforme sur le territoire.

La question de recherche qui structure cette étude est double : (i) comment les facteurs environnementaux influencent-ils la densité parasitaire observée chez les enfants testés, et (ii) quel seuil d'altitude peut raisonnablement définir une zone prioritaire pour l'intervention ?

L'analyse s'appuie sur une base de données de 250 enfants testés, décrite par huit variables : l'altitude du lieu de résidence (`Altitude_m`), la température moyenne (`Temperature_C`), le taux d'humidité relative (`Humidity_pct`), le niveau de précipitations (`Precipitation_mm`), la distance au point d'eau le plus proche (`Dist_to_Water_m`), le type de sol (`Soil_Type` : Sable, Argile, Terre franche), le nombre d'oiseaux observés dans la zone comme indicateur indirect de biodiversité (`Bird_Count`), et la variable cible, la densité parasitaire dans le sang (`Parasite_Density_ul`). L'identifiant de l'enfant (`Child_ID`) a été exclu du modèle car il s'agit d'une variable purement technique sans contenu explicatif.

2. Volet 1 — Cadre Théorique

2.1 Pourquoi la distribution brute de la densité parasitaire peut-elle poser problème dans un modèle OLS ?

La densité parasitaire est, par nature, une variable de comptage/concentration biologique strictement positive, dont la distribution est typiquement asymétrique à droite (*right-skewed*) : une majorité d'individus présente une charge parasitaire modérée, tandis qu'une minorité présente des charges très élevées, créant une longue traîne. Ce type de distribution pose plusieurs problèmes potentiels pour une régression linéaire estimée par moindres carrés ordinaires (OLS) :

- **Hétéroscédasticité** : la variance des erreurs a tendance à croître avec le niveau de la variable dépendante, violant l'hypothèse de variance constante des résidus.
- **Non-normalité des résidus** : si Y est fortement asymétrique, les résidus du modèle linéaire risquent de ne pas suivre une loi normale, ce qui invalide les tests de significativité usuels (test t , test F) qui reposent sur cette hypothèse en échantillon fini.
- **Sensibilité aux valeurs extrêmes** : les individus à très forte densité parasitaire (queue de distribution) peuvent exercer un effet de levier disproportionné sur l'estimation des coefficients, biaisant l'interprétation de l'effet moyen des variables explicatives.
- **Prédictions incohérentes** : un modèle linéaire non contraint peut, dans certains cas, prédire des densités parasitaires négatives, ce qui n'a pas de sens biologique.

En pratique, ce risque théorique doit être vérifié empiriquement sur les données réelles avant de décider d'une transformation (log, racine carrée) ou d'un modèle alternatif (régression binomiale négative, modèle log-linéaire). C'est précisément l'objet du diagnostic de résidus effectué au Volet

2 : si les résidus se révèlent normaux et homoscedastiques, l'OLS reste justifié malgré le risque théorique initial ; dans le cas contraire, une transformation ou un modèle non-linéaire serait nécessaire.

2.2 Que suggère le théorème de Gauss-Markov ?

Le théorème de Gauss-Markov établit que, sous un ensemble précis d'hypothèses, l'estimateur des Moindres Carrés Ordinaires (MCO/OLS) est le **Meilleur Estimateur Linéaire Non Biaisé** (BLUE — *Best Linear Unbiased Estimator*), c'est-à-dire l'estimateur de variance minimale parmi tous les estimateurs linéaires non biaisés du vecteur de coefficients β . Ces hypothèses sont :

- Linéarité du modèle en les paramètres : $E(Y|X) = X\beta$.
- Exogénéité stricte : $E(\varepsilon|X) = 0$, les erreurs ne sont pas corrélées avec les régresseurs.
- Homoscedasticité : $\text{Var}(\varepsilon_i) = \sigma^2$ constante pour tous les individus i .
- Absence d'autocorrélation : $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ pour $i \neq j$.
- Absence de multicollinéarité parfaite entre les variables explicatives.

Le théorème ne requiert pas explicitement la normalité des résidus pour garantir la propriété BLUE ; en revanche, la normalité est nécessaire pour que les tests d'inférence usuels (test t sur chaque coefficient, test F global, intervalles de confiance) soient exacts en échantillon fini plutôt qu'asymptotiques. Gauss-Markov suggère donc une démarche méthodologique claire : avant d'interpréter les coefficients et les p -values d'un modèle OLS, il est impératif de vérifier empiriquement ces hypothèses — en particulier l'homoscedasticité et la normalité des résidus — plutôt que de les supposer acquises. C'est cette vérification qui est menée au §3.3 ci-après.

3. Volet 2 — Modélisation Statistique

3.1 Préparation des données

La base contient 250 observations et 8 variables : deux variables entières (`Altitude_m`, `Bird_Count`), cinq variables réelles (`Temperature_C`, `Humidity_pct`, `Precipitation_mm`, `Dist_to_Water_m`, et la variable cible `Parasite_Density_ul`), et une variable catégorielle à trois modalités (`Soil_Type` : Sable, Argile, Terre franche). La variable `Child_ID` a été supprimée en amont car elle n'a pas de valeur explicative.

L'examen des valeurs manquantes révèle un taux inférieur à 6 % sur deux variables climatiques seulement :

Variable	% de valeurs manquantes
Altitude_m	0,0 %
Temperature_C	4,4 %
Humidity_pct	5,2 %
Precipitation_mm	0,0 %
Dist_to_Water_m	0,0 %
Soil_Type	0,0 %
Bird_Count	0,0 %
Parasite_Density_ul	0,0 %

TABLE 1 – Taux de valeurs manquantes par variable

Un simple retrait des lignes incomplètes (`dropna`) aurait été possible, mais l'analyse exploratoire bivariée (`pairplot`) a mis en évidence une forte relation linéaire entre l'altitude et la température (la température décroît avec l'altitude selon le gradient thermique altitudinal attendu), ainsi qu'une

relation inverse marquée entre l'altitude et la densité parasitaire, et une relation positive entre température et densité parasitaire — cohérente avec la biologie du vecteur anophèle, dont le cycle de développement est accéléré par la chaleur. Ces relations ont justifié une stratégie d'imputation plus fine que la suppression pure et simple : les valeurs manquantes de **Temperature_C** ont été imputées par une régression linéaire simple sur l'altitude (meilleur prédicteur identifié graphiquement), tandis que les lignes avec **Humidity_pct** manquante ont été supprimées (le lien avec les autres variables étant moins net). Après ce traitement, l'échantillon final utilisé pour la modélisation comprend **237 observations complètes**.

3.2 Modèle de régression linéaire complet (6 variables)

Un premier modèle OLS a été estimé sur la densité parasitaire (**Parasite_Density_ul**) expliquée par l'ensemble des six variables numériques disponibles : **Altitude_m**, **Temperature_C**, **Humidity_pct**, **Precipitation_mm**, **Dist_to_Water_m** et **Bird_Count**.

Variable	Coef.	Err.-type	<i>t</i>	<i>P</i> > <i>t</i>	IC 95 %
Constante	5882,15	668,47	8,80	0,000	[4565,0 ; 7199,3]
Altitude_m	-1,3973	0,150	-9,29	0,000	[-1,694 ; -1,101]
Temperature_C	9,2245	19,785	0,47	0,641	[-29,76 ; 48,21]
Humidity_pct	2,1721	1,848	1,18	0,241	[-1,47 ; 5,81]
Precipitation_mm	0,3893	0,293	1,33	0,186	[-0,19 ; 0,97]
Dist_to_Water_m	-0,1676	0,056	-2,99	0,003	[-0,278 ; -0,057]
Bird_Count	2,4984	9,266	0,27	0,788	[-15,76 ; 20,76]

TABLE 2 – Modèle OLS complet à 6 variables — $R^2 = 0,884$, R^2 ajusté = 0,881, $F = 291,6$ ($p < 0,001$), AIC = 3563,52

Ce modèle complet affiche un pouvoir explicatif très élevé : $R^2 = 0,884$ (R^2 ajusté = 0,881), et le test F global est hautement significatif ($F = 291,6$; $p < 0,001$), ce qui indique que l'ensemble des variables explique conjointement une part très importante de la variance de la densité parasitaire. Cependant, l'examen des p -values individuelles montre que seules deux variables sont statistiquement significatives au seuil de 5 % : **Altitude_m** ($p < 0,001$) et **Dist_to_Water_m** ($p = 0,003$). Les quatre autres variables — **Temperature_C**, **Humidity_pct**, **Precipitation_mm** et **Bird_Count** — ne sont pas significatives une fois l'altitude et la distance à l'eau prises en compte, suggérant une redondance informationnelle (notamment entre température et altitude, corrélées entre elles) plutôt qu'une absence réelle de lien biologique.

3.3 Vérification des hypothèses de Gauss-Markov

Avant d'interpréter davantage le modèle, les hypothèses de Gauss-Markov ont été contrôlées sur les résidus du modèle complet, à l'aide d'un QQ-plot et d'un graphique des résidus contre les valeurs prédites.

- **QQ-Plot des résidus** : les points s'alignent quasiment parfaitement sur la diagonale théorique, sans courbure en S ni décrochage aux extrémités, ce qui indique une distribution des résidus proche de la normalité.
- **Résidus vs valeurs prédites** : le nuage de points est dispersé de façon aléatoire autour de la ligne horizontale nulle, sans forme de banane (ce qui confirme la linéarité de la relation) ni forme d'entonnoir (ce qui confirme l'homoscédasticité, c'est-à-dire une variance constante des erreurs).

Ce diagnostic visuel a été confirmé formellement par un **test de Shapiro-Wilk** sur les résidus : statistique = 0,9942, p -value = 0,4934. La p -value très supérieure au seuil de 5 % conduit à ne pas rejeter l'hypothèse nulle de normalité : les résidus du modèle suivent bien une loi normale.

Conclusion du diagnostic : les hypothèses de Gauss-Markov (linéarité, homoscedasticité, normalité des résidus, absence de structure résiduelle) sont respectées sur ces données. L'estimateur OLS est donc statistiquement fiable ici : ses coefficients sont BLUE et les tests d'inférence (p -values, intervalles de confiance) sont valides et interprétables sans réserve, malgré le risque théorique évoqué au Volet 1 pour une variable de densité parasitaire.

3.4 Sélection des variables significatives par le critère AIC

Une procédure de sélection *backward* (élimination séquentielle en arrière) fondée sur le critère d'information d'Akaike (AIC) a été appliquée à partir du modèle à six variables. À chaque étape, la variable la moins significative (p -value la plus élevée) est retirée si, et seulement si, ce retrait améliore (diminue) l'AIC du modèle ; la procédure s'arrête dès qu'aucun retrait supplémentaire n'améliore l'AIC.

Étape	Variable retirée	p -value	AIC après retrait
0 (initial)	—	—	3563,52
1	Bird_Count	0,788	3561,59
2	Temperature_C	0,649	3559,81
3	Humidity_pct	0,237	3559,24
4	Precipitation_mm	0,181	3559,06

TABLE 3 – Séquence de sélection backward par critère AIC

La procédure a retiré successivement Bird_Count, Temperature_C, Humidity_pct puis Precipitation_mm, faisant passer l'AIC de 3563,52 (modèle complet) à 3559,06. Le modèle final retenu ne conserve que deux variables : Altitude_m et Dist_to_Water_m.

Variable	Coef.	Err.-type	t	$P > t $	IC 95 %
Constante	6540,84	66,75	97,99	0,000	[6409,3 ; 6672,3]
Altitude_m	-1,4241	0,034	-41,53	0,000	[-1,492 ; -1,357]
Dist_to_Water_m	-0,1597	0,055	-2,89	0,004	[-0,269 ; -0,051]

TABLE 4 – Modèle final retenu par AIC — $R^2 = 0,882$, R^2 ajusté = 0,881, $F = 875,1$ ($p < 0,001$), AIC = 3559,06, Cond. No. = $4,37 \times 10^3$

Ce modèle final, plus parcimonieux, conserve un pouvoir explicatif quasi identique au modèle complet ($R^2 = 0,882$ contre 0,884), tout en étant nettement plus robuste sur le plan statistique : le F -statistique passe de 291,6 à 875,1, l'indice de conditionnement (Cond. No.) chute de $4,63 \times 10^4$ à $4,37 \times 10^3$ (signe d'une multicollinéarité fortement réduite), et les deux variables retenues sont significatives à un seuil très strict ($p < 0,001$ pour l'altitude, $p = 0,004$ pour la distance à l'eau). Ce résultat confirme que l'essentiel de l'information prédictive contenue dans la température, l'humidité, les précipitations et le nombre d'oiseaux était en réalité déjà capté, de façon indirecte, par l'altitude et par la distance au point d'eau.

3.5 Interprétation de l'effet de l'altitude

Le coefficient associé à Altitude_m dans le modèle final est de -1,4241 (erreur-type 0,034 ; $p < 0,001$; IC 95 % [-1,492 ; -1,357]). Cette estimation signifie que, toutes choses égales par ailleurs (à distance au point d'eau constante), chaque élévation supplémentaire de 1 mètre est associée à une baisse moyenne de 1,42 unité de densité parasitaire (μL). Autrement dit, pour une hausse de 100 mètres d'altitude, la densité parasitaire attendue diminue en moyenne d'environ 142 unités.

Cette relation négative et très fortement significative est cohérente avec la biologie connue du vecteur : à haute altitude, les températures plus fraîches ralentissent le cycle de développement du

parasite chez le moustique (sporogonie) et raccourcissent la durée de vie effective de l'anophèle adulte, réduisant mécaniquement l'intensité de la transmission. L'altitude agit ici comme une variable synthétique, capturant indirectement l'effet thermique (via le gradient altitude-température observé dans les données) tout en restant, elle, mesurée sans erreur et sans valeur manquante, ce qui explique sa robustesse statistique supérieure à celle de la température brute.

La distance au point d'eau (`Dist_to_Water_m`) présente un coefficient négatif de $-0,1597$ ($p = 0,004$) : plus un enfant réside loin d'un point d'eau stagnante, plus sa densité parasitaire attendue est faible, ce qui est également cohérent avec la biologie du vecteur, dont les gîtes larvaires se situent à proximité immédiate des points d'eau.

Sur le plan opérationnel, l'ampleur du coefficient de l'altitude permet d'esquisser un ordre de grandeur pour un seuil de priorisation : dans cet échantillon, l'altitude varie de façon suffisamment large pour que la densité parasitaire attendue chute significativement au-delà de certains paliers. Les zones situées sous un seuil d'altitude bas (typiquement en dessous de 1000–1200 m dans les configurations climatiques comparables à celles observées ici) et proches des points d'eau stagnante cumulent les deux facteurs de risque identifiés comme significatifs, et doivent donc être considérées comme prioritaires.

4. Volet 3 — Note Stratégique : Priorisation Géographique des Interventions

À : Direction régionale de la Santé Publique — Programme National de Lutte contre le Paludisme

Objet : Recommandations pour le ciblage géographique des ressources de lutte antivectorielle sur la base de l'analyse statistique des déterminants de la densité parasitaire

4.1 Constat statistique

L'analyse de régression menée sur 237 observations complètes montre que, parmi l'ensemble des facteurs environnementaux mesurés (température, humidité, précipitations, distance à l'eau, altitude, biodiversité aviaire), seuls deux déterminants demeurent statistiquement robustes et opérationnellement exploitables une fois les redondances éliminées par sélection AIC : l'altitude du lieu de résidence et la distance au point d'eau stagnante le plus proche. Ces deux variables expliquent à elles seules 88,2 % de la variance de la densité parasitaire observée ($R^2 = 0,882$), un pouvoir explicatif quasi identique à celui du modèle complet à six variables, mais obtenu avec un modèle bien plus robuste et directement actionnable.

4.2 Recommandations opérationnelles

- **Cartographier les zones prioritaires** en combinant deux critères simples et mesurables sur le terrain sans équipement climatique sophistiqué : une altitude basse et une proximité immédiate d'un point d'eau stagnante (mares, étangs, rizières, retenues). Ces deux informations sont disponibles à moindre coût via des données topographiques existantes (modèles numériques de terrain) et une cartographie des points d'eau, sans nécessiter de stations météorologiques locales.
- **Concentrer en priorité** la distribution de moustiquaires imprégnées d'insecticide de longue durée (MILDA) et les campagnes de pulvérisation intra-domiciliaire dans les localités situées sous le seuil d'altitude critique identifié, en particulier lorsque ces localités sont également proches de points d'eau stagnante — la combinaison des deux facteurs représentant le risque cumulé maximal.
- **Renforcer l'assainissement des gîtes larvaires** (drainage, comblement, larvicides) autour des points d'eau situés dans les zones de basse altitude, où l'effet de la distance à l'eau sur la densité parasitaire est le plus marqué.

- **Ne pas prioriser** les campagnes de sensibilisation ou de collecte de données sur la seule base de la température ou de l'humidité mesurées localement : ces variables, bien que biologiquement pertinentes, n'apportent pas d'information supplémentaire significative une fois l'altitude prise en compte, et leur suivi représente donc un coût de collecte qui n'est pas justifié par un gain prédictif mesurable dans ce contexte.
- **Mettre en place un suivi longitudinal simple** dans les zones de basse altitude proches de l'eau (indicateur de densité parasitaire chez les enfants) afin de valider dans la durée l'efficacité du ciblage et d'ajuster le seuil d'altitude retenu au fil des campagnes.

4.3 Limites et prudence méthodologique

Cette recommandation repose sur un modèle linéaire dont la validité statistique a été vérifiée (résidus normaux et homoscedastiques, test de Shapiro-Wilk non significatif), ce qui garantit la fiabilité des coefficients estimés sur cet échantillon. Elle demeure toutefois une analyse corrélationnelle : elle identifie des associations robustes et biologiquement plausibles entre l'environnement et la densité parasitaire, mais ne constitue pas, à elle seule, une preuve causale directe. Il est recommandé de confirmer le seuil d'altitude opérationnel par une analyse complémentaire (par exemple une régression avec effet de seuil ou une classification par zones) et de l'ajuster progressivement à la lumière des données de terrain issues du déploiement initial, avant généralisation à l'ensemble du territoire national.

5. Conclusion Générale

Cette étude confirme, sur des données réelles rigoureusement diagnostiquées, que l'altitude et la distance au point d'eau constituent les deux déterminants environnementaux robustes de la densité parasitaire du paludisme dans l'échantillon analysé, au détriment d'un ensemble plus large de variables climatiques dont l'apport informationnel s'est révélé redondant. La méthode de sélection par critère AIC a permis de passer d'un modèle à six variables, difficile à interpréter en raison de la multicollinéarité, à un modèle parcimonieux, statistiquement plus robuste et directement transposable en critère de priorisation géographique pour les autorités sanitaires. La recommandation qui en découle — cibler les zones de basse altitude proches des points d'eau stagnante — offre un critère de terrain simple, peu coûteux à mettre en œuvre, et fondé sur une base statistique solide.